BIG DATA: TECHNOLOGY

STORAGE AND ANALYTICS





STORAGE AND ANALYTICS

- ฐานข้อมูล RDBMS แบบเดิมเป็นเทคโนโลยีที่เหมาะสมที่สุดในการเก็บข้อมูลแบบ Structure แต่ถ้าข้อมูลมีขนาดใหญ่มากก็จะเจอปัญหาเรื่องต้นทุนที่สูง และหากข้อมูลมีจำนวนเป็น PetaByte เป็นเรื่องยากที่จะเก็บข้อมูลที่มีขนาดใหญ่ขนาดนี้ ถึงแม้ในปัจจุบันจะมี MPP Datanbase อย่าง Oracle ExaDta หรือ SAP HANA แต่มีค่าใช้จ่ายสูง

- Hadoop HDFS เป็นเทคโนโลยีที่กำลังได้รับความนิยม หน่วยงานส่วนใหญ่เริ่มวางแผนนำมาใช้ในอนาคต เพราะมีความต้องการเก็บข้อมูลขนาดใหญ่ทั้งที่เป็น Unstrucure Data และที่เป็น structure โดยสามารถจะเก็บข้อมูลขนาดใหญ่ที่มีขนาดถึง PetaByte ทั้งนี้ขึ้นอยู่กับจำนวนเครื่องที่มีอยู่ในลักษณะ scale-out ข้อสำคัญ Hadoop มีต้นทุนที่ค่อนข้างต่ำเมื่อเทียบกับเทคโนโลยีที่ใช้สำหรับเก็บข้อมูลแบบอื่น

STORAGE AND ANALYTICS

- NoSQL เป็นเทคโนโลยีที่ต้องการเก็บข้อมูลจำนวนมากกว่าของ RDBMS ในลักษณะ scale-out เป็นจำนวนหลาย TeraByte แต่อาจไม่ได้เน้นเรื่องความมั่นคงของข้อมูล NoSQL จะเหมาะกับ Application บางประเภท เราสามารถแบ่งเทคโนโลยี NoSQL ออกไปได้สี่กลุ่มคือ Column Oriented, Document Oriented, Key-Value และ Graph

- Cloud Storage ข้อมูลขนาดใหญ่ขององค์กรบางส่วนอาจจำเป็นต้องเก็บไว้ใน Public Cloud Storage เช่น Amazon S3 โดยเฉพาะข้อมูลภายนอกอาทิเช่น Social Media Data หรือข้อมูลที่เป็น Archiving ที่ไม่ได้มีความสำคัญมาก เพราะ Cloud Storage จะมีราคาในการเก็บที่ถูก และสามารถที่จะเก็บได้โดยมีขนาดไม่จำกัด แต่ข้อเสียคือเรื่องความปลอดภัยและความเร็วในการถ่ายโอนข้อมูล

STORAGE AND ANALYTICS

- การประมวลผลข้อมูลที่เป็น Big Data จะมีทั้งการวิเคราะห์ข้อมูลที่เป็น business intelligence (BI) เพื่อที่จะดึงข้อมูลมานำเสนอหรือการทำ Predictive Analytics

- SQL ก็เป็นภาษาที่ยังต้องใช้ในการประมวลผลข้อมูลโดยเฉพาะ Structure Data ที่เก็บอยู่ใน RDBMS และสามารถประมวลผลแบบ RealTime ได้

- APIs ข้อมูลที่เก็บอยู่ใน Storage ต่าง ๆที่กล่าวมาข้างต้นเช่น NoSQL หรือ Cloud Storage อาจจำเป็นต้องพัฒนาด้วยโปรแกรมภาษาคอมพิวเตอร์ต่าง ๆ ในการประมวลผลข้อมูลโดยใช้ APIs ในการเข้าถึงข้อมูล

STORAGE AND ANALYTICS

- MapReduce เป็นเทคโนโลยีที่พัฒนาโดย Google ในการประมวลผลข้อมูลที่อยู่ใน HDFS โดยใช้ภาษาคอมพิวเตอร์อย่าง Java ในการพัฒนาโปรแกรม โดยจะประมวลผลแบบ Batch และเป็นวิธีการประมวลผลที่มากับเทคโนโลยี Hadoop

- Hive หรือ Pig เป็นภาษาที่คล้าย SQL หรือ Scripting ที่ทำให้เราสามารถประมวลผลข้อมูลที่อยู่ใน Hadoop HDFS ได้โดยไม่ต้องพัฒนาโปรแกรม MapReduce แต่ทั้งนี้ข้อมูลจะต้องอยู่ในรูปแบบที่เหมาะสมเช่น ไฟล์ csv หรือไฟล์ข้อความบางประเภท

STORAGE AND ANALYTICS

- Impala เป็นภาษาคล้าย SQL ที่สามารถประมวลผลข้อมูลที่อยู่ใน Hadoop HDFS ได้ โดยทำงานได้รวดเร็วกว่า Hive มาก แต่มีข้อเสียคือเป็นภาษาที่เป็น proprietary ของ Cloudera

- Spark เป็นเทคโนโลยีที่สามารถประมวลผลข้อมูลขนาดใหญ่แบบ Realtime โดยอาจมี Data Source มาจากหลากหลายแหล่งเช่น RDBMS, Cloud Storage, NoSQL หรือ Hadoop ซึ่งสามารถเขียนโปรแกรมโดยใช้ภาษา Scala, Java, Python หรือจะเขียนโดยใช้ภาษาคล้าย SQL ก็ได้ และมี Library สำหรับการทำ Data Science คือ MLib เป็นเทคโนโลยีที่น่าสนใจมากอันหนึ่ง

STORAGE AND ANALYTICS

- ภาษาและเทคโนโลยีในการทำ Machine Learning ซึ่งก็จะมีหลากหลายทั้ง Hadoop, Mahout, Azure Machine Learning หรือ AWS ML

- เทคโนโลยีสำหรับการทำ Data Visualisation และ BI อาทิเช่น Tableau, Pentaho, SaS, Excel และอื่น ๆ

บุคลากรในการจัดการข้อมูลขนาดใหญ่

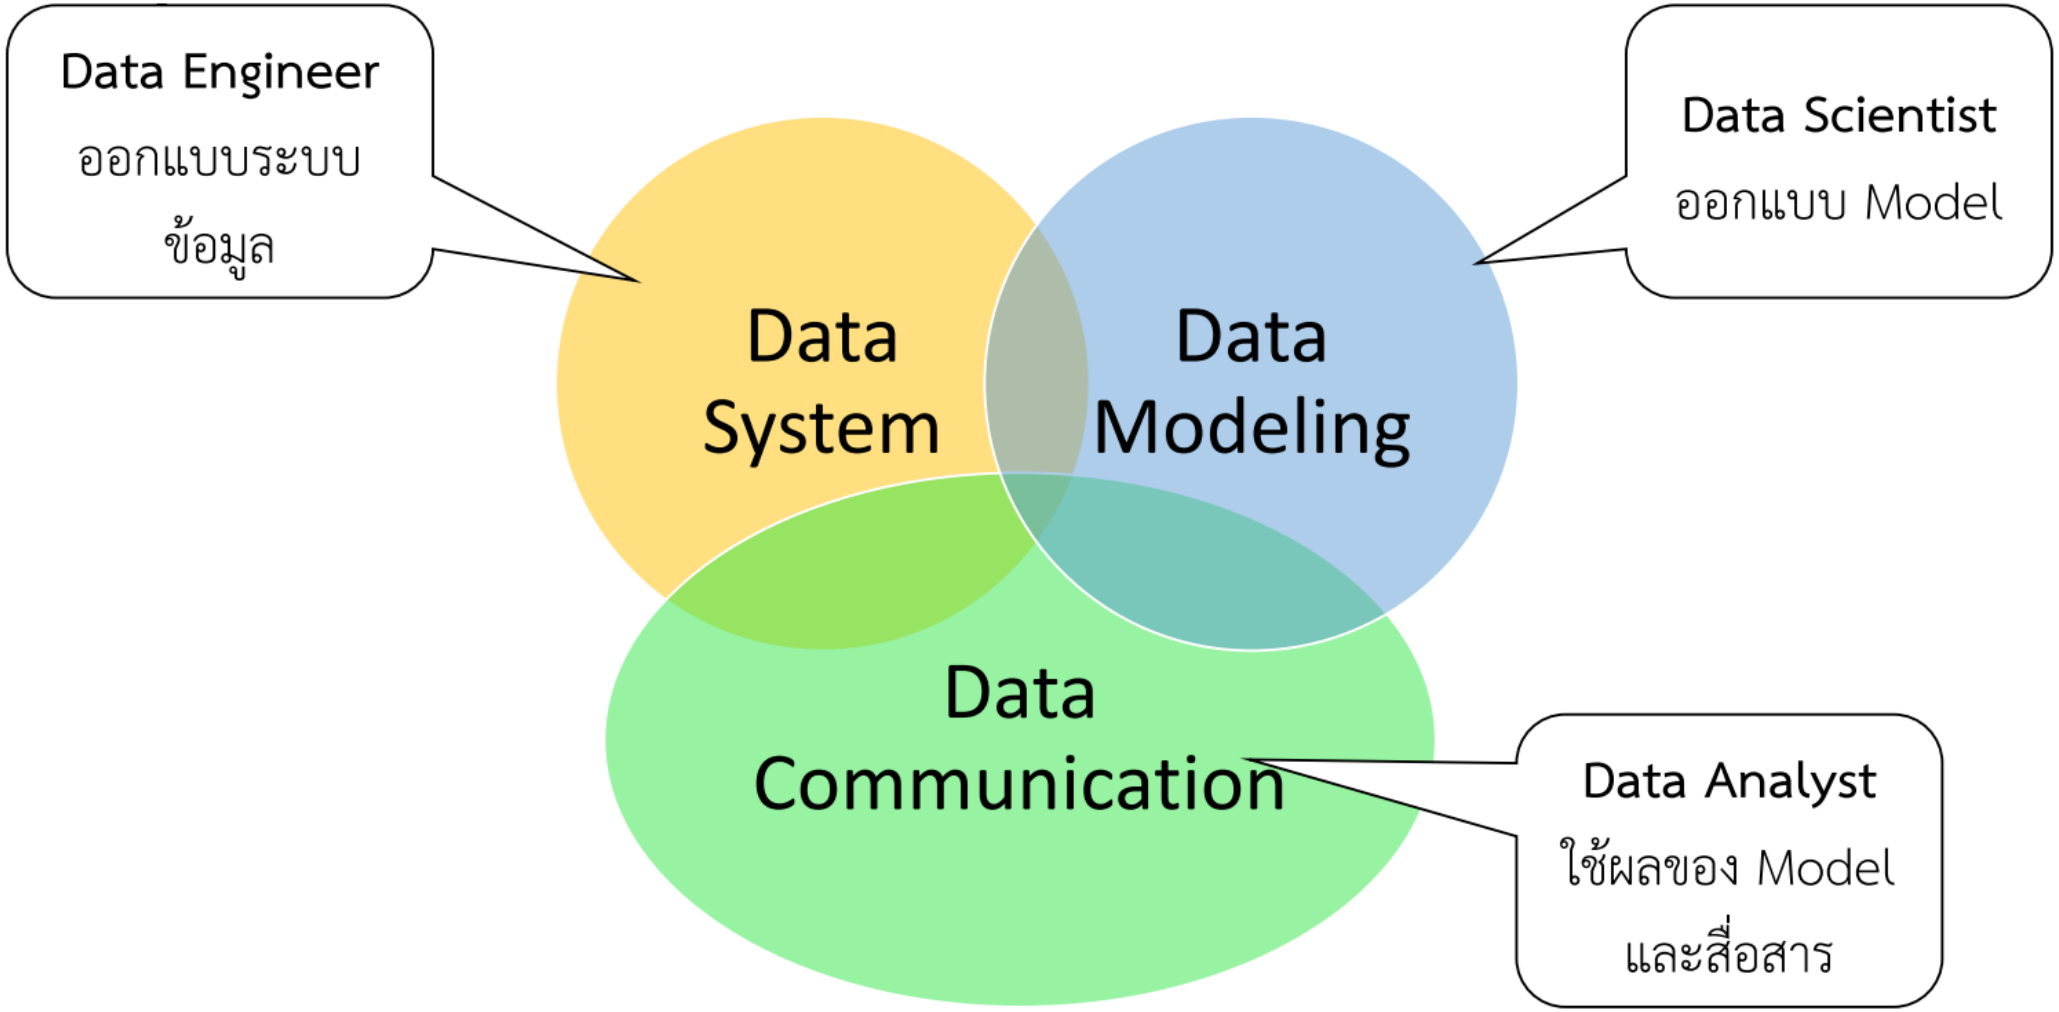
ประกอบไปด้วย 3 ผู้เชี่ยวชาญหลัก (Data Expert) ดังนี้

1. Data System กลุ่มงานนี้จะมี Data Engineer ทำหน้าที่ในการออกแบบระบบการไหลของข้อมูล การจัดโครงสร้าง การจัดเก็บข้อมูล และช่องทางการนำผลลัพธ์ที่ได้จากการประมวลผลไปแสดงผล

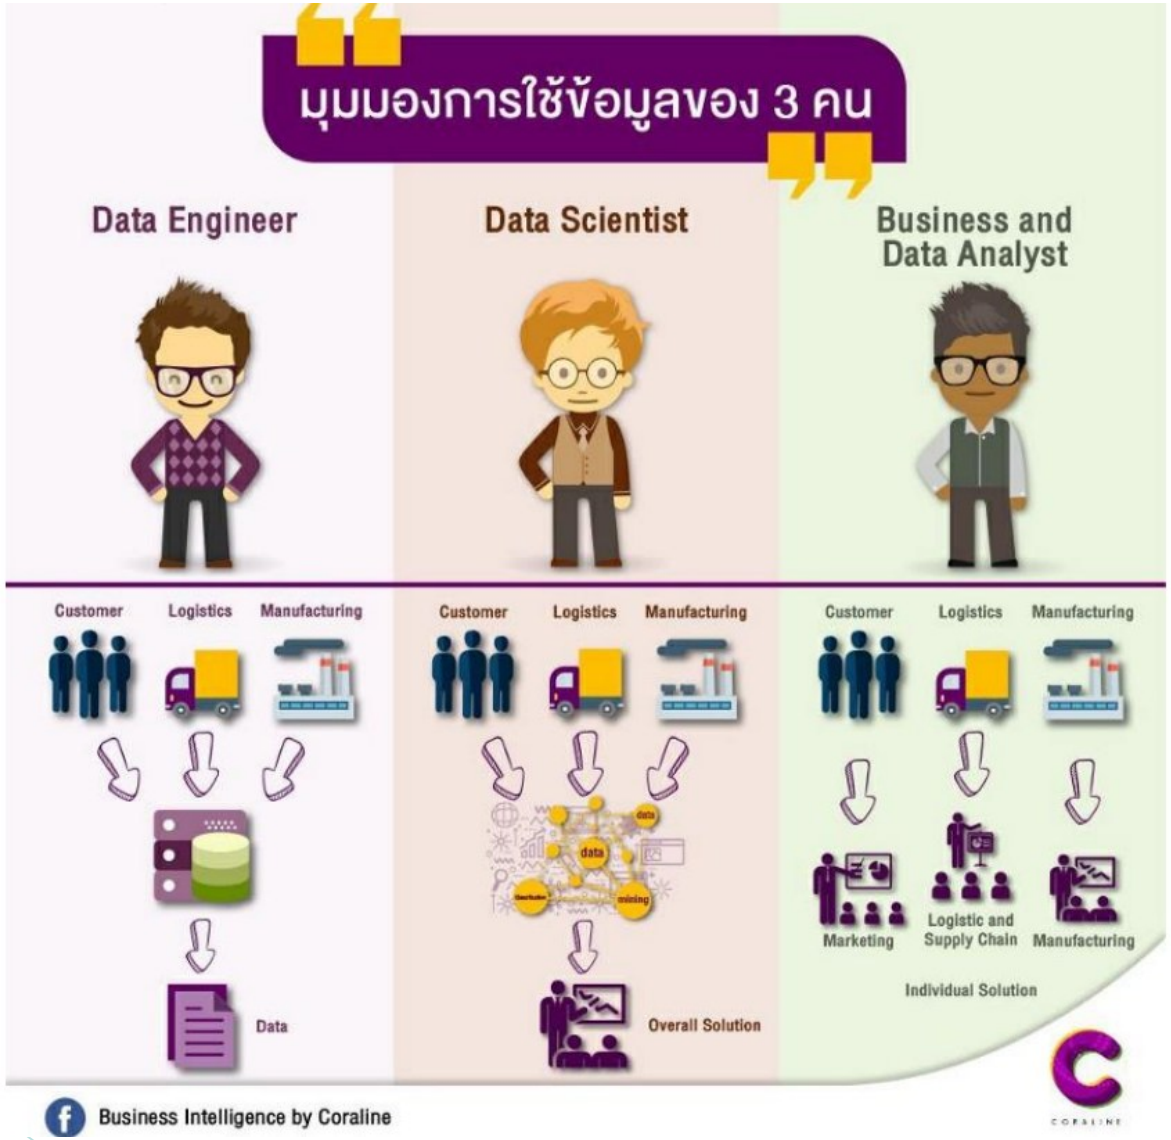
2. Data Modeling กลุ่มงานนี้จะมี Data Scientist ทำหน้าที่สร้างแบบจำลอง (Model) ที่เหมาะสม โดยการนำข้อมูลขนาดใหญ่เป็นต้นแบบ และมองหาผลลัพธ์เชิงลึก (Insight) จากการสร้าง Data Model

3. Data Communication กลุ่มงานนี้จะมี Data Analyst ทำหน้าที่ใช้ข้อมูลผลลัพธ์ที่ได้จาก Model ไปใช้งานและสื่อสารต่อ และยังเป็นผู้ประเมินปัญหา และประเมินผลลัพธ์จาก Model

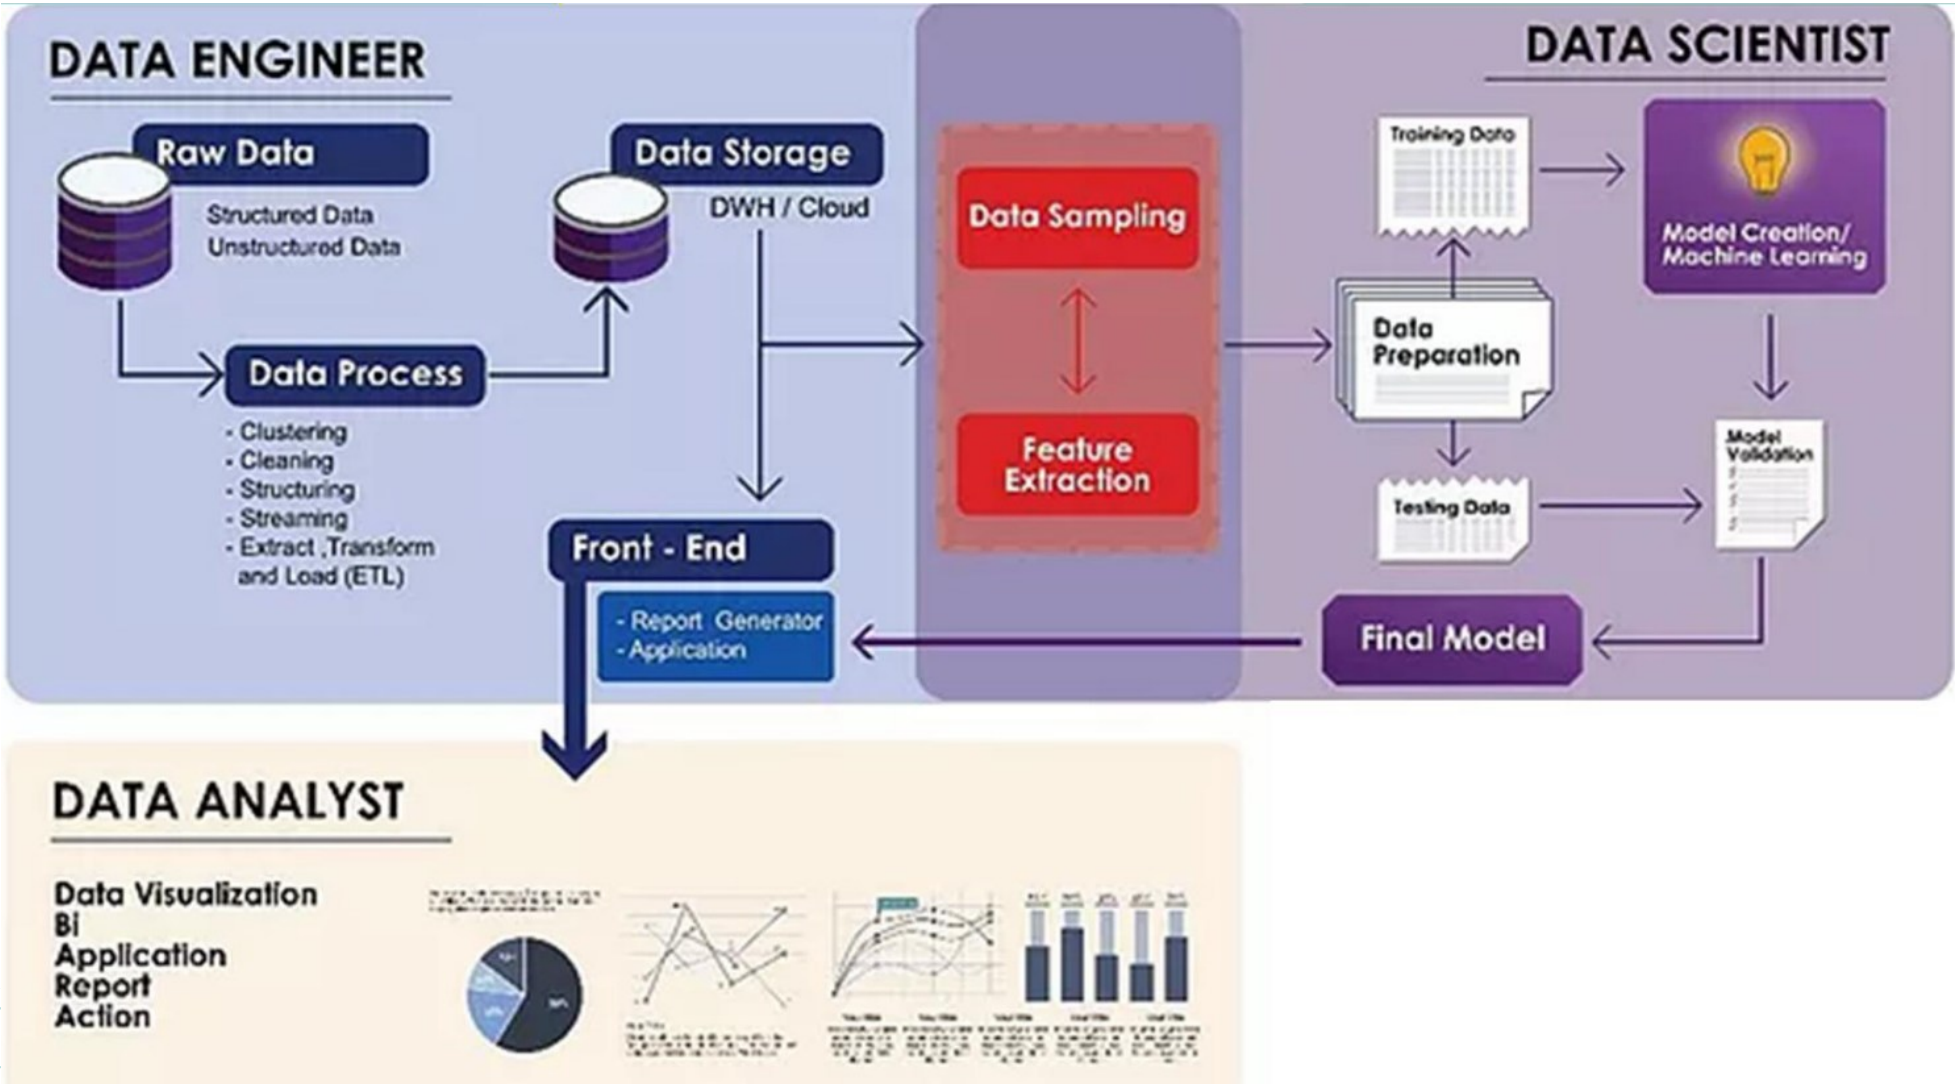
บุคลากรในการจัดการข้อมูลขนาดใหญ่



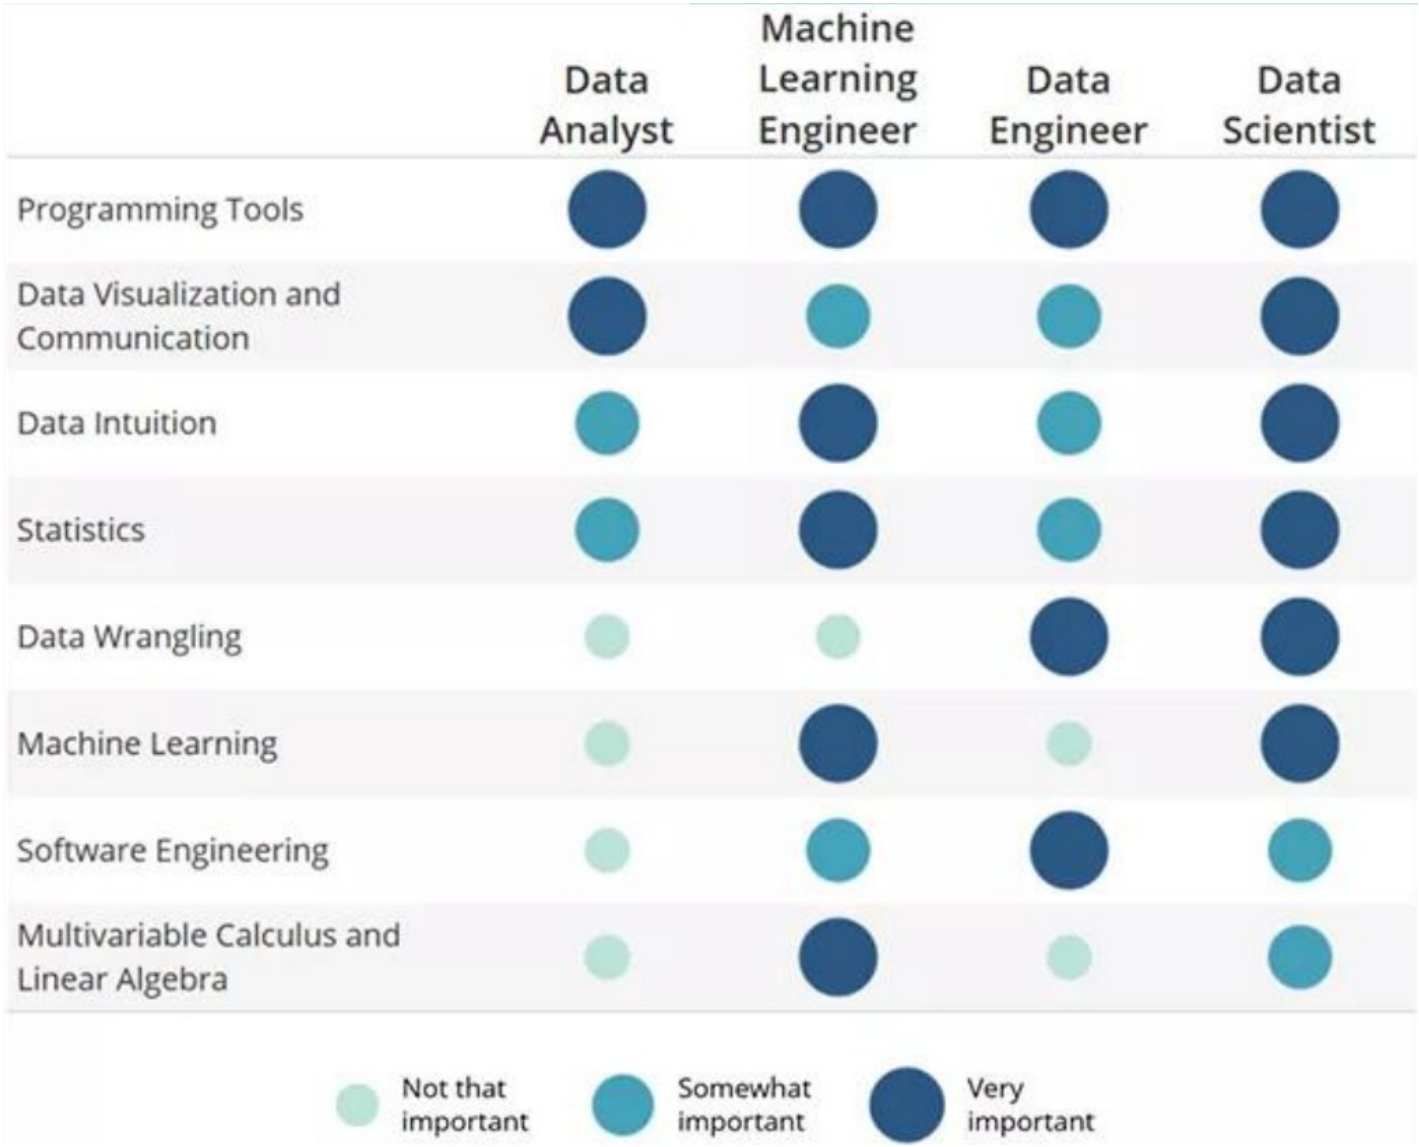
บุคลากรในการจัดการข้อมูลขนาดใหญ่



บุคลากรในการจัดการข้อมูลขนาดใหญ่

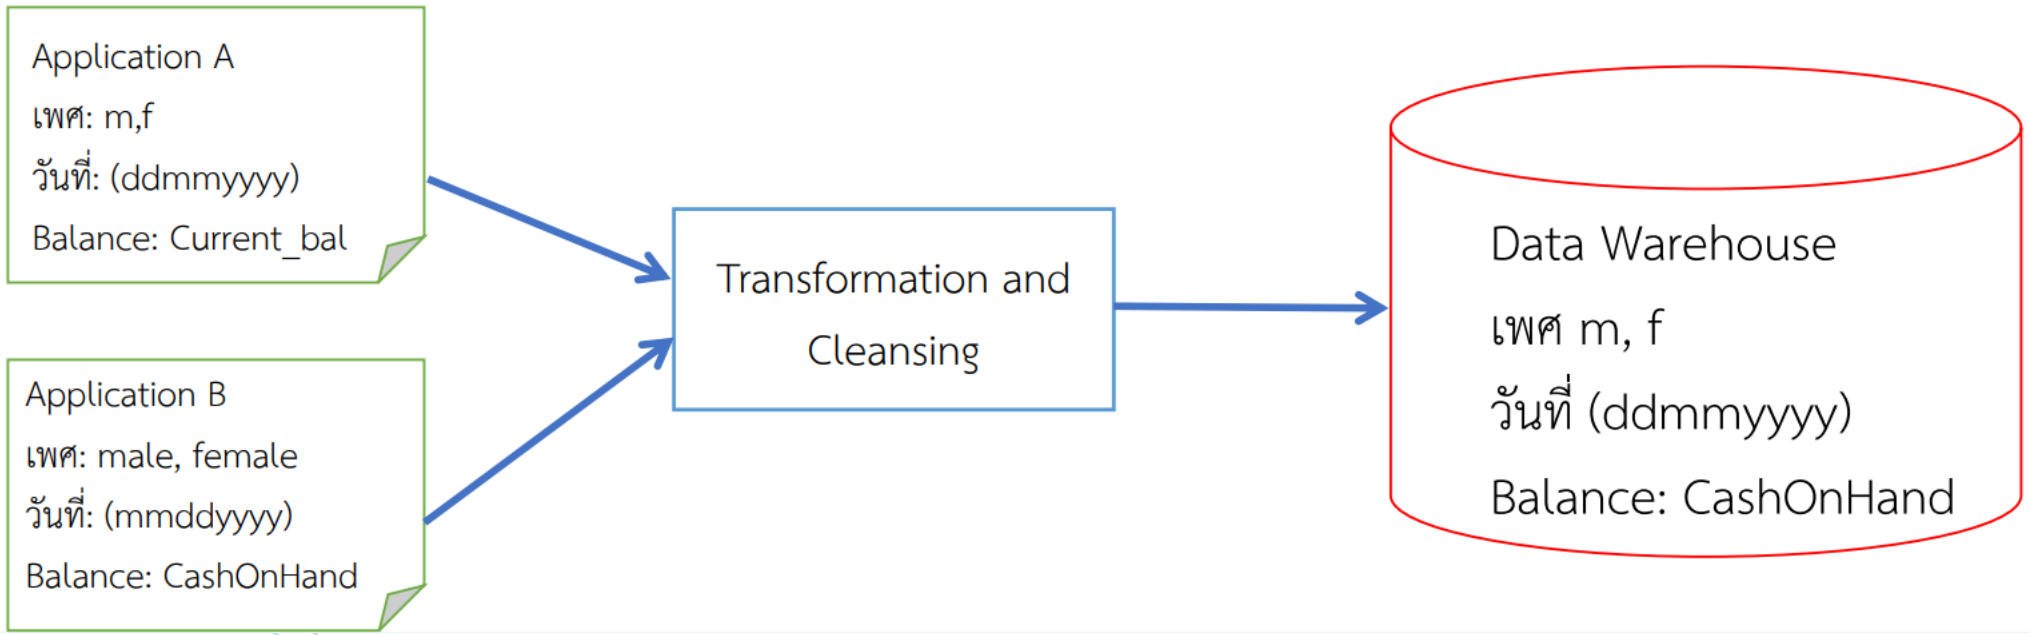


SKILLS


Data Analyst
Machine Learning Engineer
Data Engineer
Data Scientist
Programming Tools
Data Visualization and Communication
Data Intuition
Statistics
Data Wrangling
Machine Learning
Software Engineering
Multivariable Calculus and Linear Algebra
Not that important
Somewhat important
Very important

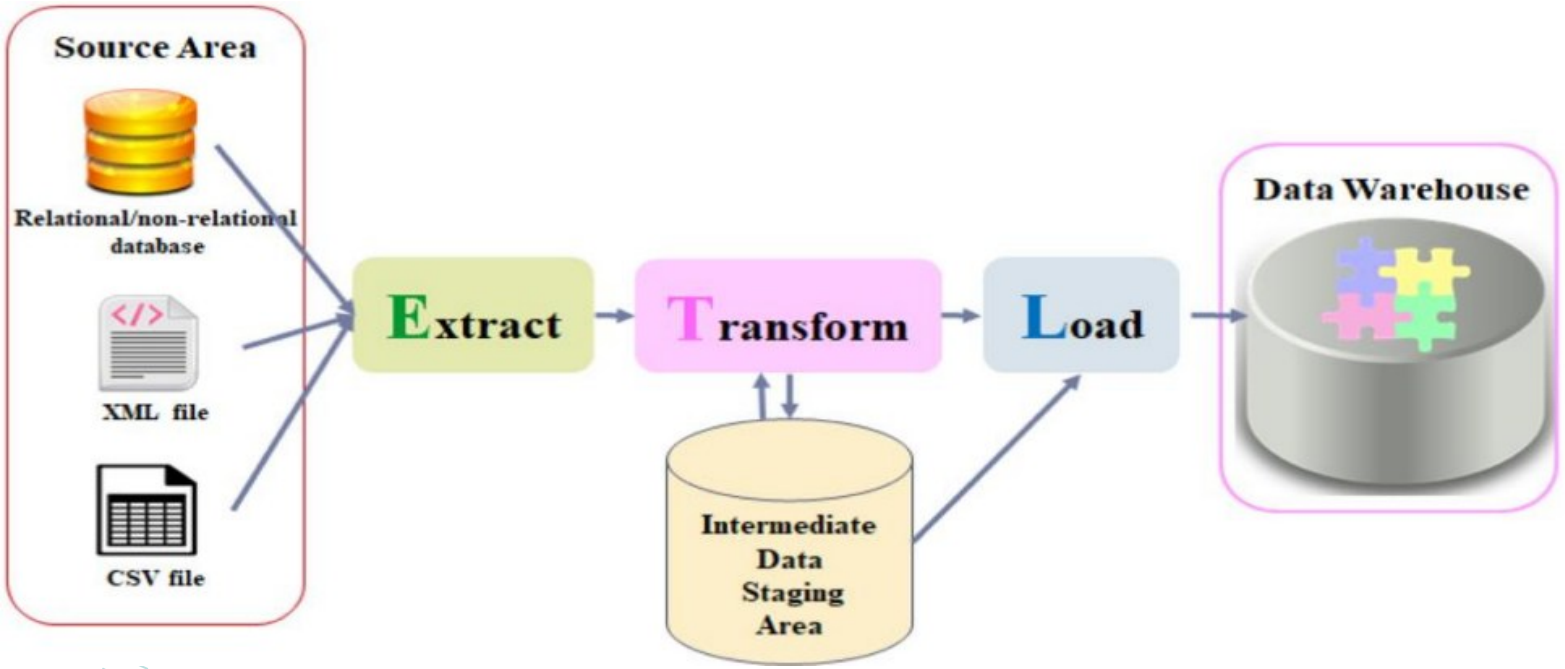
ETL

เป็นการนำข้อมูล (Extract) จากหลากหลายแหล่งข้อมูล เช่น จากฝ่าย Marketing, จากฝ่าย Sale, จากฝ่าย Customer Service ฯลฯ มาแปลงรูปแบบให้เหมาะสม (Transform) แล้วเก็บ (Load) เข้าไปใน Data Warehouse หรือ Data Lake

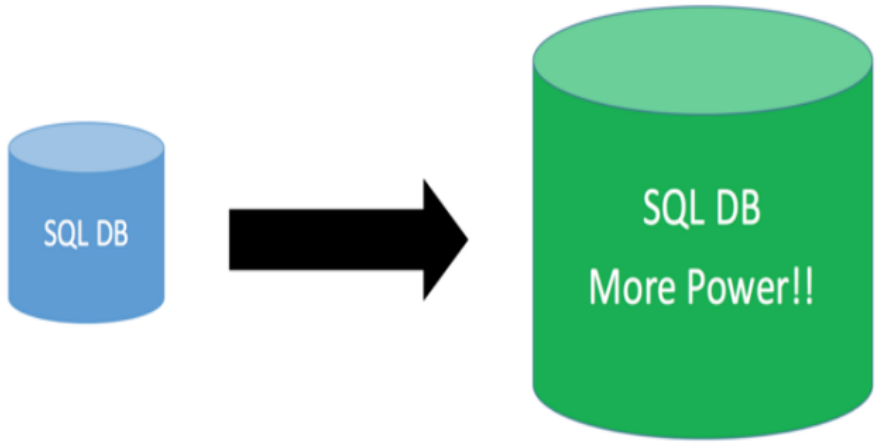


ETL

- สามารถเอาข้อมูลชุดนี้ไปให้ทีม Analytics ประมวลผลต่อหรือเอาไปทำ Dashboard สรุปให้ผู้บริหาร
- นำข้อมูลระบบเก่า (Legacy System) มารวมกับระบบใหม่



SCALING UP



- To scale up the system
- เพิ่มความเร็วการทำงาน เพิ่มประสิทธิภาพ ETL
- เลือกใช้ HDD ที่มีประสิทธิภาพในการอ่านและเขียนข้อมูลได้เร็ว
- เพิ่มRAM CPU Network เพื่อเพิ่มประสิทธิภาพการประมวลผล

SCALING OUT

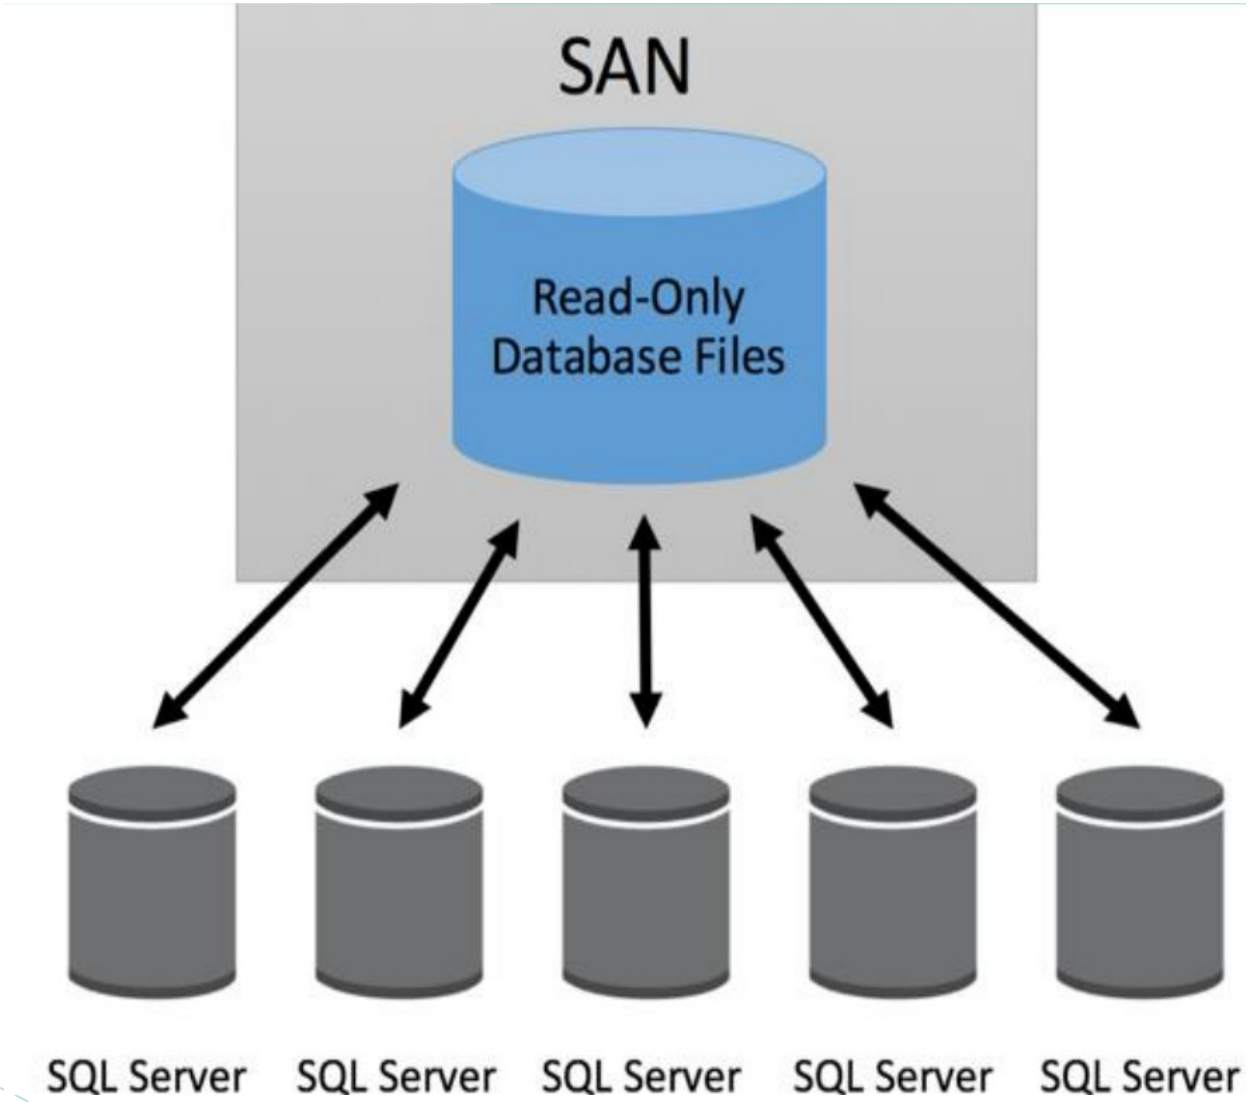
- Scaling out แนวทางการดำเนินการจะตรงข้ามกับ Scaling up

- จะสร้างระบบที่ใหญ่ขึ้นเป้าหมายคือการกระจายภาระการประมวลผลไปยังระบบขนาดเล็กจำนวนมากแทน

- วิธีที่ง่ายที่สุดในการปรับขนาดฐานข้อมูล SQLคือการใช้เครือข่ายพื้นที่เก็บข้อมูล (SAN) เพื่อจัดเก็บข้อมูล

- ใช้เซิร์ฟเวอร์ SQL สำหรับการค้นหาข้อมูล วิธีนี้จะกระจายโหลดระหว่างเซิร์ฟเวอร์ทั้งหมดที่ทำงานร่วมกัน

SCALING OUT A SQL DATABASE



ELT

- Extraction: This first step involves copying data from the source system.

- Loading: During the loading step, the pipeline replicates data from the source into the target system, which might be a data warehouse or data lake.

- Transformation: Once the data is in the target system, organizations can run whatever transformations they need. Often organizations will transform raw data in different ways for use with different tools or business processes.

BIG DATA TECHNOLOGY



Source: edureka.co