UNDERSTANDING BIG DATA



Woottikarn Hongwiengchan

BIG DATA คืออะไร

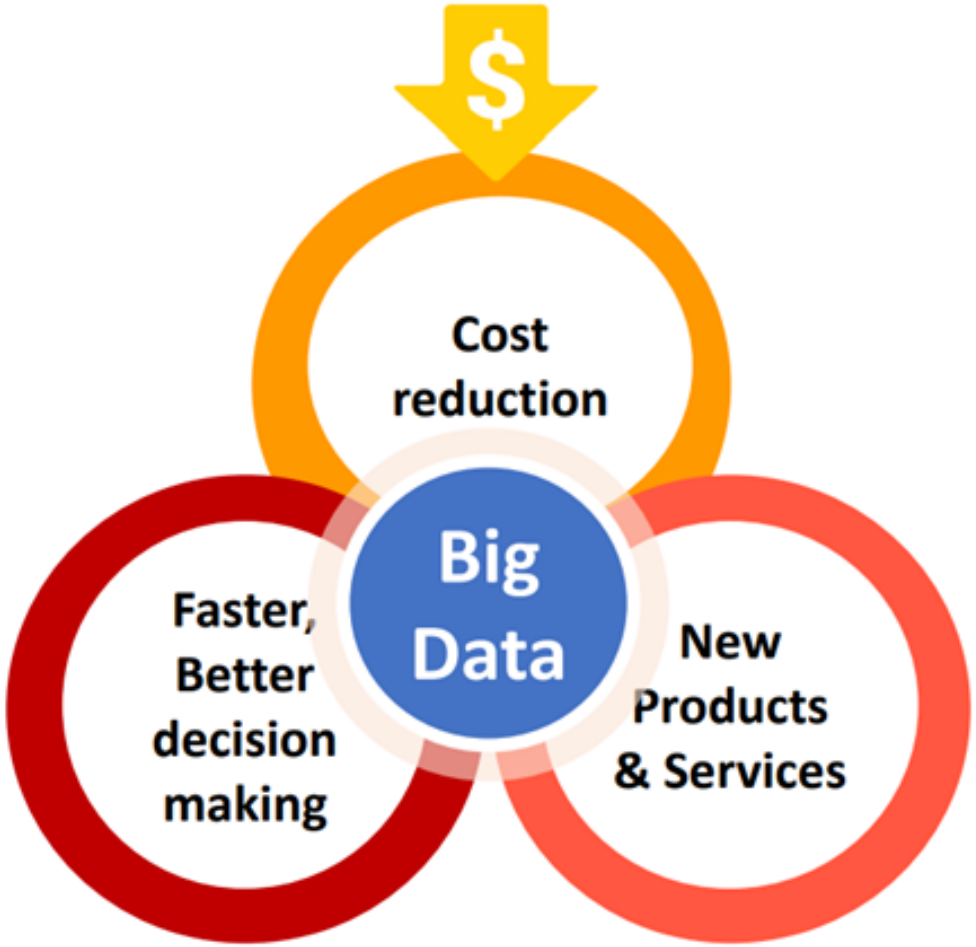
กระบวนการรวบรวม การจัดเก็บ การประมวลผล การวิเคราะห์ข้อมูลที่มีความหลากหลายของประเภทข้อมูล ข้อมูลมีขนาดใหญ่ มีปริมาณมาก และมีความซับซ้อนสูงมาอยู่รวมกัน โดยที่เครื่องมือในการจัดการข้อมูลทั่วไป (traditional processing software) ไม่สามารถประมวลผลได้

BIG DATA มาจากไหน

Big Data จริงๆแล้วเกิดมาจากตัวเรา ยกตัวอย่างเช่น ทุกการกดคลิก กด Like หรือคอมเมนท์ บน Facebook จะถูกบันทึกไว้แล้วเก็บเป็นข้อมูล ถ้าคนไม่กี่คนใช้งาน Facebook ข้อมูลที่เก็บไว้ก็จะมีไม่มาก แต่ถ้าคนหลายล้านคนมาใช้งานพร้อมกัน ทั้งยังถล่ม คอมเมนท์ Like แบบ real-time และเล่นกันเกือบทั้งวัน ปริมาณของข้อมูลที่เก็บจึงมีจำนวนมหาศาล

นอกจากพวกเราที่ขยันช่วยกันสร้างข้อมูลแล้ว อุปกรณ์ดิจิตอลอย่างพวก IoT (Internet of Thing) ก็เป็นอีกหนึ่งผู้ท้าชิงในการผลิตข้อมูล แล้วนำไปสร้างโมเดล หรือ Machine Learning ทำให้เกิดข้อมูลขึ้นเป็นจำวนมากจนก่อให้เกิดเป็นข้อมูลแบบ Big Data

WHY BIG DATA

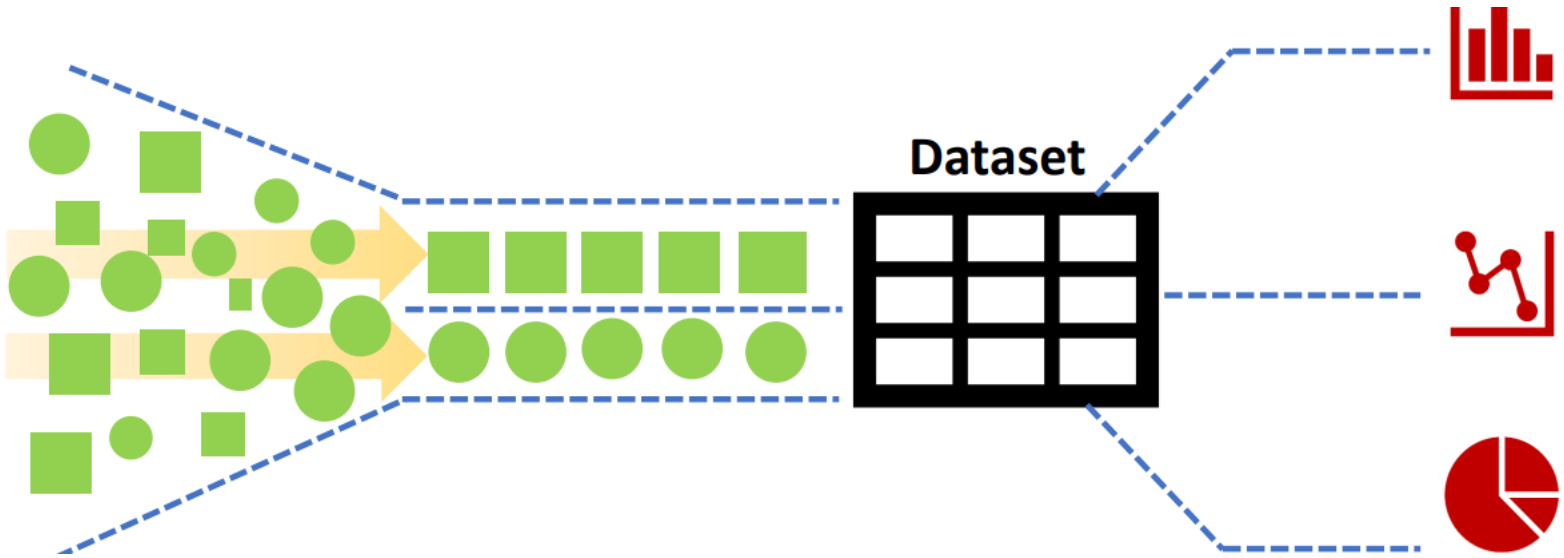

$
Cost reduction
Big Data
Faster, Better decision making
New Products & Services

DATASETS

Datasets : ชุดข้อมูลหรือกลุ่มข้อมูลที่เกี่ยวข้องกัน ซึ่งอาจจะอยู่ในหลากหลายรูปแบบ เช่น ไฟล์ข้อมูล รูปภาพ ตารางข้อมูล เป็นต้น

DATASETS

Datasets : ชุดข้อมูลหรือกลุ่มข้อมูลที่เกี่ยวข้องกัน ซึ่งอาจจะอยู่ในหลากหลายรูปแบบ เช่น ไฟล์ข้อมูล รูปภาพ ตารางข้อมูล เป็นต้น



SOURCES OF OPEN DATASETS

- UCI Machine Learning Repository!
http://archive.ics.uci.edu/ml/index.php

- World Bank Open Data
https://data.worldbank.org/

- Kaggle Open Datasets and Machine Learning Projects
https://www.kaggle.com/datasets

- UNICEF Dataset
https://data.unicef.org/

- Google Public Data Explorer
https://www.google.com/publicdata/directory

- Google Dataset Search

https://datasetsearch.research.google.com/

- Open Data Thailand
https://data.go.th/

คุณสมบัติของ BIG DATA

1. Volume (ปริมาณ)

ขึ้นชื่อว่า Big Data แน่นอนว่าจำเป็นต้องเป็นข้อมูลที่มี “ปริมาณมหาศาล” เพราะในการกำหนดคุณค่าของข้อมูล ปริมาณถือเป็นบทบาทที่สำคัญมาก ข้อมูลใดสามารถถือเป็น Big Data ได้จริงหรือไม่นั้น จะขึ้นอยู่กับปริมาณข้อมูล ยิ่งข้อมูลเยอะ โอกาสที่จะได้ insight จากข้อมูล Big Data นั้นก็ยิ่งเยอะตาม ซึ่งโดยปกติแล้วข้อมูลที่เป็น Big Data จะเริ่มต้นกันที่หลัก Terabytes ไปจนถึง Petabytes

คุณสมบัติของ BIG DATA

2. Velocity (ความเร็ว)

Velocity จะหมายถึง “ความเร็วในการสะสมข้อมูล” ในกรณีของ Big Data ข้อมูลจะไหลเข้าจากแหล่งต่างๆ เช่น เครื่องจักร, โซเชียลมีเดีย หรือโทรศัพท์มือถือ อย่างรวดเร็วในปริมาณที่สูงและต่อเนื่อง ยิ่งข้อมูลถูกสร้างขึ้นและประมวลผลได้เร็วมากเท่าไหร่ ก็ยิ่งตอบสนองความต้องการได้เร็วขึ้น และมีข้อมูลถูกอัพเดทแบบ Realtime ตลอดเวลา

คุณสมบัติของ BIG DATA

3. Variety (ความหลากหลาย)

Variety จะหมายถึง ธรรมชาติของข้อมูลแบบ Big Data ที่มีหลากหลาย เช่น ข้อความ, รูปภาพ, เสียง, วิดีโอ โดยรูปแบบของข้อมูล Big Data จะได้แก่

- ข้อมูลที่มีโครงสร้าง (Structured data)
- ข้อมูลกึ่งโครงสร้าง (Semi- Structured data)
- ข้อมูลไม่มีโครงสร้าง (Unstructured data)

ประเภทของข้อมูล

มีทั้งหมด 3 รูปแบบ

1. Structured data เป็นข้อมูลที่มีการจัดเก็บไว้ในรูปแบบหรือโครงสร้างที่ชัดเจนนักวิทยาศาสตร์ข้อมูลสามารถนำไปใช้ได้ง่ายเช่น ข้อมูลที่อยู่ในรูปของไฟล์ CSV หรือไฟล์ Excel ซึ่งข้อมูลในรูปแบบนี้จะอยู่ในรูปแบบตาราง ถ้าเราลองสังเกตเวลาใช้งานข้อมูลรูปแบบนี้จะเห็นหัวข้ออยู่ตรงแถวกับคอลัมน์ทำให้เราสามารถเข้าใจถึงข้อมูลได้ในทันที และสามารถนำมาจัดเรียงข้อมูลใน Database สามารถนำเอาไปใช้ในโปรแกรม SQL อย่างง่ายดาย ตัวอย่างของข้อมูล Structured data ได้แก่ ข้อมูลในตาราง Excel เช่น ชื่อ, อายุ, น้ำหนัก, ส่วนสูง ซึ่งข้อมูลเหล่านี้สามารถนำเอาไปใช้งานได้เลยทันที

ประเภทของข้อมูล

2. Unstructured data เป็นข้อมูลที่ไม่มีโครงสร้างที่ชัดเจน หลายคนอาจจะงงกับคำว่าข้อมูลที่ไม่มีโครงสร้างถ้าจะพูดให้ง่ายขึ้นข้อมูลเหล่านี้จะเป็นข้อมูลในรูปแบบของรูปภาพ คลิปวิดีโอ ไฟล์เสียง หรือเป็นข้อความที่เราคุยกันบนโลกออนไลน์ ซึ่งจะเห็นได้ว่าข้อมูลเหล่านี้มีจำนวนมากกว่าข้อมูลในรูปแบบ Structured data และเป็นข้อมูลที่ทำให้เกิด Big Data

ประเภทของข้อมูล

3. Semi-structured data ข้อมูลกึ่งโครงสร้างเกิดจากการอยู่ระหว่างกลางของ Structure data ซึ่งเป็นข้อมูลที่สามารถนำไปใช้งานได้ง่าย แต่มีความยากในการกำหนดโครงสร้างเพื่อจัดเก็บข้อมูล และ Unstructured data ซึ่งเป็นข้อมูลที่ยากต่อการนำไปใช้งาน แต่ง่ายในการจัดเก็บ

ซึ่ง Semi-structured data เอาข้อดีของข้อมูลทั้ง 2 รูปแบบมาคือใช้การเก็บข้อมูลในรูปแบบของ Unstructured data แต่ทำให้อยู่ในรูปแบบที่พร้อมใช้งานได้ง่ายเหมือนกับ Structure data

ตัวอย่างข้อมูลในรูปแบบ Semi-structured data ได้แก่ Hash-tag ตามโลกออนไลน์ซึ่งรูปแบบการเก็บข้อมูลคือจะเป็นโพสต์หรือรูปภาพ แต่เราสามารถดึงมาใช้งานได้ง่ายขึ้นจากการที่เราเลือก Hash-tag ที่เฉพาะเจาะจง

คุณสมบัติของ BIG DATA

4. Veracity (ความถูกต้อง)

Veracity เป็น V ตัวที่ 4 ที่หมายถึง “ความถูกต้องและน่าเชื่อถือของข้อมูล” ซึ่งเพิ่มมาจาก 3V เมื่อหลายปีก่อน เนื่องจากเมื่อมีข้อมูลมาขึ้นเลยทำให้ทราบว่า ข้อมูลที่เยอะ, หลากหลาย และรวดเร็ว หากไม่มีความถูกต้องก็อาจนำไปใช้งานได้ไม่เต็มที่ และอาจจะได้ข้อมูลเชิงลึกที่ไม่เป็นความจริง

ข้อมูลบางครั้งก็อาจยุ่งเหยิงและใช้งานยาก เพราะข้อมูลจำนวนมากที่ขาดความจริงหรือครบถ้วนอาจส่งผมเสียได้ เช่น ในด้านการแพทย์ หากข้อมูลเกี่ยวกับยาที่ผู้ป่วยกำลังรับประทานไม่ครบถ้วน ชีวิตของผู้ป่วยอาจตกอยู่ในอันตรายได้ เพราะฉะนั้น Big Data จึงควรมีคุณลักษณะของความถูกต้องอยู่ด้วย

คุณสมบัติของ BIG DATA

5. Value

หลังจากพิจารณาทั้ง 4V ที่แล้ว ยังมี V อีกหนึ่งตัวที่เป็นคุณลักษณะ Big Data ที่สำคัญที่สุดใน 5V นั่นก็คือ Value หรือ “คุณค่าของข้อมูล” การมีข้อมูลจำนวนมากแต่ไม่มีค่านั้นไม่ดีต่อบริษัท เว้นแต่คุณจะเปลี่ยนเป็นสิ่งที่มีประโยชน์ ข้อมูลในตัวมันเองไม่มีประโยชน์หรือมีความสำคัญ แต่หากเรานำมาแปลงหรือวิเคราะข้อมูลเพื่อนำ insight ออกมาจากข้อมูล ข้อมูล Big Data ก็จะสร้างมูลค่ามหาศาลให้กับองค์กรของคุณได้

องค์ประกอบของ BIG DATA

1. Data Source

แหล่งข้อมูลของ Big Data นั้นอาจจะมาจากหลากหลายแหล่ง เช่น โปรแกรม, ข้อมูลธุรกรรม (transaction),อุปกรณ์ต่างๆ หรืออุปกรณ์ IOT ทำให้มีความยากในการจัดการข้อมูลเนื่องจากแต่ละแหล่งมีโครงสร้างข้อมูลที่ต่างกัน

องค์ประกอบของ BIG DATA

2. Ingestion

การส่งผ่านข้อมูลเป็นขั้นตอนแรกของ Big Data Ecosystem ในการดึงข้อมูลดิบ โดยข้อมูลดิบนั้นจะมาจากทั้งแหล่งข้อมูลภายใน (internal sources), ฐานข้อมูลเชิงสัมพันธ์ (relational databases), ฐานข้อมูลที่ไม่ใช่เชิงสัมพันธ์ (non-relational databases) และแหล่งอื่นๆอีกมากมาย ซึ่งการนำเข้าข้อมูลจะมีหลักๆ 2 ประเภท คือ

องค์ประกอบของ BIG DATA

2.1 Batch เป็นการรวบรวมและส่งผ่านกลุ่มข้อมูล Big Data ขนาดใหญ่ไปด้วยกัน โดยการใช้งานจะต้องถูกกระตุ้นโดยเงื่อนไข เช่น ตั้งเวลาไว้ หรือ เรียกใช้เฉพาะกิจ

2.2 Streaming เป็นการไหลของข้อมูลแบบต่อเนื่อง ซึ่งจำเป็นอย่างมากสำหรับการวิเคราะห์ข้อมูลแบบเรียลไทม์

องค์ประกอบของ BIG DATA

3. Storage

การเก็บข้อมูลขนาดใหญ่ หรือ Big Data ในปัจจุบันมักจะเก็บไว้ใน Data Warehouse หรือ Data Lake ซึ่งอาจจะนำมาพักไว้เพื่อให้พร้อมนำไปใช้งานต่อในการวิเคราะห์ หรือเก็บข้อมูลในอดีตก็ได้

โดย Data Warehouse จะเป็นการเก็บข้อมูล Big Data แบบดั้งเดิมที่เก็บได้เฉพาะข้อมูลที่มีโครงสร้างชัดเจน หรือกึ่งโครงสร้างจากหลายแหล่ง ส่วน Data Lake จะยืดหยุ่นกว่า และเก็บข้อมูลได้ทั้งข้อมูลที่มีโครงสร้างชัดเจนและข้อมูลที่ไม่มีโครงสร้างแน่นอน ซึ่งการเลือกใช้ก็ขึ้นอยู่กับเงื่อนไขหรือความต้องการในการนำ Big Data ไปใช้งานขององค์กร

องค์ประกอบของ BIG DATA

4. Analysis

เมื่อมีข้อมูลดิบในแหล่งข้อมูลแล้ว เราจะสามารถนำข้อมูล Big Data มาจัดเตรียมและทำความสะอาด (Data Cleansing) เพื่อเข้าสู่กระบวนการวิเคราะห์ข้อมูลได้ โดยกระบวนการวิเคราะห์ข้อมูลมักจะได้แก่

DATA CLEANSING

ข้อมูลเป็นแบบนี้จะทำอย่างไรให้ข้อมูลถูกต้อง
อยู่ในรูปแบบเดียวกัน
นำไปใช้วิเคราะห์ได้ และเชื่อถือได้ ?

วันที่	รายการสินค้า	จำนวน	ราคาขาย	รวมรายได้	ราคาส่ง	ต้นทุน	กำไร
3/4/2562	นมต้มเกษตรมช.	20	20.00	400.00	22.00	440.00	-40.00
3/4/2562	ข้าวแช่คั่ว (ซอง)	3	15.00	45.00	15.00	45.00	0.00
3/4/2562	ถั่วมิกส์นัท (กระป๋อง)	3	15.00	45.00	15.00	45.00	0.00
3/4/2562	ถั่วลายเสือคั่ว (กระป๋อง)	1	63.00	63.00	63.00	63.00	0.00
4/4/2562	ถั่วมิกส์นัท (ซอง)	1	15.00	15.00	15.00	15.00	0.00
4/4/2562	ข้าวแช่คั่ว (กระป๋อง)	1	59.00	59.00	59.00	59.00	0.00
4/4/2562	ข้าวแช่คั่ว (ซอง)	3	15.00	45.00	15.00	45.00	0.00
4/4/2562	ถั่วมิกส์นัท (กระป๋อง)	1	75.00	75.00	75.00	75.00	0.00
4/4/2562	นมต้มเกษตรมช.	20	20.00	400.00	18.00	360.00	40.00
4/4/2562	ถั่วลายเสือคั่ว (กระป๋อง)	1	63.00	63.00	59.00	59.00	4.00
4/4/2562	ถั่วเหลืองคั่ว (กระป๋อง)	1	57.00	57.00	57.00	57.00	0.00
5/4/2562	ถั่วมิกส์นัท (ซอง)	2	15.00	30.00	15.00	30.00	0.00
5/4/2562	ข้าวแช่คั่ว (ซอง)	1	15.00	15.00	15.00	15.00	0.00
5/4/2562	ข้าวแช่คั่ว (ซอง)	1	15.00	15.00	15.00	15.00	0.00

แบรนด์	จังหวัด
นมต้มเกษตรม	เชียงใหม่
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	MHS
ถั่วคุณลุง	แมฮ่องสอน
ถั่วคุณลุง	แม่ฮ่่่่องสอน
ถั่วคุณลุง	แม่ฮ่่่่องสอน
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	มฮส.
นมต้มเกษตรม	ชม.

Garbage in Garbage out
หากไม่ทำ Cleansing

ANALYSIS

4.1 สถิติเชิงพรรณา หรือ Descriptive Analytics เช่น ค่าเฉลี่ย ผลรวม
4.2 ความสัมพันธ์ของตัวแปร หรือ Diagnostics Analytics เช่น Correlation
4.3 การพยากรณ์หรือทำนายอนาคต หรือ Predictive Analytics เช่น Machine Learning
4.4 การวิเคราะห์แบบให้คำแนะนำ หรือ Prescriptive analytics เช่น Optimization

*ซึ่งการวิเคราะห์จะขึ้นอยู่กับชนิดและบริบทของข้อมูล Big Data นั้น รวมถึงสิ่งที่องค์กรอยากรู้เกี่ยวกับข้อมูล

องค์ประกอบของ BIG DATA

5. Consumption

การนำผลลัพธ์ไปใช้ถือเป็นองค์ประกอบสำคัญของ Big Data ซึ่งการนำข้อมูล Big Data จากการวิเคราะห์ไปใช้อาจอยู่ในรูปแบบ Data Visualization เช่น ตาราง ,กราฟ, Dashboard สวยๆ หรืออาจจะเป็น insight ที่ตอบคำถามทางธุรกิจ หรือส่งผลต่อการตัดสินใจขององค์กรได้